


Full first200 调度策略系统性能报告

实验配置

项目	配置
数据规模	7 个 dataset，每个随机选取 200 条，共 1,400 requests
数据顺序	长度过滤后按 seed 20260709 随机抽样，mixed workload 全局随机打乱
数据集	gsm8k, strategyqa, mmlu_pro, math, mbpp, hotpotqa, swebench_verified
长度过滤	start prompt < 14000 tokens; start prompt + op max tokens <= 15500
模型	/data2/lhy/flow/models/Llama-3.1-8B-Instruct
推理后端	real vLLM 0.16.0, CUDA / NVIDIA A800
GPU	physical GPU 3,4,5,6,7, 共 5 张
max model len	32768
output max tokens	2048 per DAG op
GPU memory utilization	0.75
到达过程	Poisson 0.15 req/s, arrival batch size 1, seed 20260709
调度策略	FCFS、SJF、SAILP
代码版本	d5d45c8

核心系统指标

策略	完成	系统总完成时间	总 tokens	输出 tokens	请求吞吐量	总吞吐量	输出吞吐量
FCFS	1400/1400	11573.6s (192.9min)	28,518,302	3,191,145	0.1210 req/s	2464.1 token/s	275.7 token/s
SJF	1400/1400	11199.7s (186.7min)	28,368,115	3,119,310	0.1250 req/s	2532.9 token/s	278.5 token/s
SAILP	1400/1400	11358.2s (189.3min)	28,473,524	3,146,169	0.1233 req/s	2506.9 token/s	277.0 token/s



请求时间指标

策略	平均等待	平均 service time	P50 service time	P95 service time	P99 service time	平均完成时间
FCFS	824.3s	34.5s	25.3s	93.4s	149.8s	858.8s
SJF	287.9s	96.9s	25.9s	198.5s	943.8s	384.8s
SAILP	3.6s	3174.1s	2440.0s	9085.2s	10045.4s	3177.7s

平均等待表示 request 到达后到第一个 op 开始；service time 表示第一个 op 开始到整个 DAG 完成。二者必须同时观察。

调度与队列指标

策略	ready queue avg / peak	dependency stall	调度开销	critical path	DAG parallelism	跨 device 依赖	负载不均衡	并行利用率
FCFS	96.3 / 237	15.6s	321.5s (2.78%)	27.6s	1.311	5.04	1.0677	91.66%
SJF	54.1 / 131	150.7s	296.8s (2.65%)	26.6s	1.315	5.48	1.0702	91.61%
SAILP	185.9 / 857	3221.2s	409.9s (3.61%)	26.9s	1.314	7.67	1.0721	91.52%


相对 FCFS 的变化

指标	优选方向	SJF vs FCFS	SAILP vs FCFS
系统总完成时间	越低越好	-3.23%	-1.86%
总 token 吞吐量	越高越好	+2.79%	+1.74%
输出 token 吞吐量	越高越好	+1.01%	+0.46%
平均等待时间	越低越好	-65.08%	-99.56%
平均 service time	越低越好	+180.62%	+9088.71%
平均完成时间	越低越好	-55.19%	+270.01%
ready queue peak	越低越好	-44.73%	+261.60%
调度开销	越低越好	-7.68%	+27.50%
dependency stall	越低越好	+862.98%	+20488.66%


百分比计算方式为：策略值 / FCFS - 1。时间、队列和 stall 指标通常越低越好；吞吐量越高越好。

Device 占用时间线

绿色表示该 device 正在执行至少一个 DAG op；空白表示没有 op 运行。内部 device 0-4 映射到 physical GPU 3-7。虚线是按 1400 / 0.15 计算的理论泊松到达窗口末端。




Physical GPU	FCFS	SJF	SAILP
3	88.78%	88.57%	88.74%
4	89.99%	89.57%	89.68%
5	91.44%	91.97%	90.65%
6	93.32%	93.15%	93.38%
7	94.79%	94.79%	95.13%



Dataset 平均 Service Time

Dataset	FCFS	SJF	SAILP
gsm8k	11.0s	8.0s	1058.0s
strategyqa	19.1s	15.3s	54.0s
mmlu_pro	23.7s	23.4s	45.1s
math	41.5s	43.0s	6173.8s
mbpp	36.0s	35.7s	4535.2s
hotpotqa	27.6s	156.0s	4979.6s
swebench_verified	82.9s	397.2s	5373.1s



结论

- 三种策略均完成 1400/1400，成功率 100%，没有 context length、OOM 或运行崩溃。
- SJF 的系统总完成时间最短：11199.7s，比 FCFS 缩短 3.23%；总吞吐量为 2532.9 token/s。
- FCFS 的平均等待较高：824.3s，但平均 service time 最短：34.5s。
- SJF 的平均完成时间为 384.8s，明显低于 FCFS；但 P99 service time 为 943.8s，存在少量长尾请求。
- SAILP 的首次等待仅 3.6s，但平均 service time 达到 3174.1s，ready queue peak 为 857，dependency stall 为 3221.2s。它快速接纳请求，却在 DAG 内部产生严重等待。
- 三种策略的 device busy 比例约 89%-95%，并行利用率约 91.5%-91.7%。性能差异主要来自执行顺序、队列积压和 DAG 内部等待，而不是 GPU 总体空闲。
- 三次运行的总 token 数差异约 0.53%。在这组配置下，SJF 是最好的系统级基线；SAILP 当前实现不适合作为请求完成时间基线。

数据边界

- 占用时间线来自结果 JSON 中每个 op 的实际 start/end 时间，是调度层 device busy/idle，不是 nvidia-smi SM utilization。
- 本次完整运行没有连续保存 GPU 硬件监控 CSV，因此不绘制显存、功耗或 SM utilization 时序。
- 完整指标：analysis/scheduler_metrics.csv。
- 相对比较：analysis/relative_vs_fcfs.csv。
- Device 数据：analysis/device_busy_comparison.csv。
- Dataset 数据：analysis/dataset_metrics.csv。