

Bench DAG 设计总览：先定形态，再配数据集

圆形节点表示 MFE operator；绿色为起点，红色为终点；蓝框为基础形态，红框为复杂综合形态。

基础形态（由简单到复杂）

chain_gsm8k_medium.yaml
4 ops, 3 edges



形态：线性链式推理

数据集：GSM8K

小学数学文字题，天然适合 parse、solve、check 的短链式逐步推理。

branch_verify_strategyqa_medium.yaml
5 ops, 5 edges



形态：隐式分解 + 双分支校验

数据集：StrategyQA

隐式多步 yes/no 常识题；支持/反驳两条路径能暴露隐藏假设。

debate_mmlu_pro_medium.yaml
7 ops, 9 edges



形态：多路并行辩论 + 裁决

数据集：MMLU-Pro

更难的多任务选择题；多名 debater 并行给出候选答案，再由 judge 裁决。

self_refine_math_medium.yaml
8 ops, 7 edges




形态：两轮数学自我批改

数据集：MATH

竞赛数学题容易出现推导漏洞；两轮 critic/revise 更贴近人工反复验算。

plan_code_test_mbpp_medium.yaml
6 ops, 6 edges




形态：计划 - 代码 - 测试

数据集：MBPP

小型 Python 编程题带自然语言需求和测试，适合计划、实现、测试审查。

复杂综合形态（尽量覆盖上面的结构特征）

parallel_debate_mapreduce_hotpotqa_medium.yaml
14 ops, 23 edges




形态：四路并行 + 辩论 + Map-Reduce

数据集：HotpotQA

多文档多跳问答；四路证据分析后辩论，再把答案、证据、推理和一致性检查 Map-Reduce 汇总。

agentic_repair_swebench_verified_medium.yaml
16 ops, 21 edges



形态：定位 + 双补丁 + 测试选择

数据集：SWE-bench Verified

真实 GitHub issue 修复任务；需要定位、补丁候选、测试验证和回归风险检查。