

Bench DAG 设计总览：先定形态，再配数据集

圆形节点表示 MFE operator；绿色为起点，红色为终点；蓝框为基础形态，红框为复杂综合形态。

基础形态（由简单到复杂）

chain_gsm8k_medium.yaml
4 ops, 3 edges

形态：线性链式推理

数据集：GSM8K

小学数学文字题，天然适合 parse、solve、check 的短链式逐步推理。

branch_verify_strategyqa_medium.yaml
5 ops, 5 edges

形态：隐式分解 + 双分支校验

数据集：StrategyQA

隐式多步 yes/no 常识题：支持/反驳两条路径能暴露隐藏假设。

debate_mmlu_pro_medium.yaml
7 ops, 9 edges

形态：多路并行辩论 + 裁决

数据集：MMLU-Pro

更难的多任务选择题：多名 debater 并行给出候选答案，再由 judge 裁决。

self_refine_math_medium.yaml
5 ops, 4 edges

形态：草稿 - 批改 - 修正

数据集：MATH

竞赛数学题更容易出现推导漏洞，适合用批改和修正节点提高稳健性。

plan_code_test_mbpp_medium.yaml
6 ops, 6 edges

形态：计划 - 代码 - 测试

数据集：MBPP

小型 Python 编程题带自然语言需求和测试，适合计划、实现、测试审查。

复杂综合形态（尽量覆盖上面的结构特征）

research_panel_gpqa_diamond_medium.yaml
16 ops, 20 edges

形态：专家组 + 证据 + 辩论 + 反思

数据集：GPQA Diamond

研究生级科学选择题，难度高，适合多专家证据、选项排除、辩论和反思。

agentic_repair_swebench_verified_medium.yaml
16 ops, 21 edges

形态：定位 + 双补丁 + 测试选择

数据集：SWE-bench Verified

真实 GitHub issue 修复任务：需要定位、补丁候选、测试验证和回归风险检查。